

OpenTPU缩写规范

- quant
 - aqt : antiquant反量化 : 激活场景 $\text{int8} \rightarrow \text{float}$
 - rqt : requant重量化 : 將1layer conv的out進行量化成整數再輸入給2layer
 - dqt : dequant : 將整數域矩陣乘/conv的int32結果轉換成float, 即恢复乘累加结果的真实值 : $\text{int8} \text{ GEMM} \rightarrow \text{int32}$, 原始值是 $\text{fp32} \rightarrow \text{quant} \rightarrow \text{int8} \rightarrow \text{GEMM} \rightarrow \text{int32} \rightarrow \text{dequant} \rightarrow \text{fp32}$
 - $y_{\text{fp32}} = y_{\text{int32}} \times (\text{scale}_x \times \text{scale}_w)$
 - 输入特征图共享一个 scale_x , 每个 filter 共享一个 scale_w
 - 所以反量化系数 $\text{dequant} = (\text{scale}_x \times \text{scale}_w)$ 是 N/C_o 的函数
 - quant : 將浮點數轉換成int8
 - $x_{\text{int8}} = \text{round}(x_{\text{fp32}} / \text{scale}_x)$
 - $w_{\text{int8}} = \text{round}(w_{\text{fp32}} / \text{scale}_w)$
- Mem
 - DDR $\leftrightarrow$ L2 $\leftrightarrow$ Global Mem
 - PMB : parameter buffer : 緩衝bias, dequant scale, sprase index (卷积/matmul参数 $\rightarrow$ MXU)
 - APB : activation parameter buffer : eg : leaky RELU (给ARU使用)
- Kernel : 单个二维卷积核, 维度是 $\text{Kernel}_h \times \text{Kernel}_w$
- Filter : C_i 个Kernel组成一个Filter, 一共有 C_o 个Filter
- 卷积层 : C_o 个Filter构成整个卷积层
- feature map : 指的是HWC 3维立方体
- feature map channel : 指的是HW 2维平面
- MN/NK/MN : left matrix/Right matrix/result matrix
- K方向 : MNK里的K, 累加方向 ($MN \times NK$)

- M0, K0, N0 : MXU unit能够完成的原子矩阵乘法
- tensor : 在L2 (DDR) 中存放的完整数据 (
feature map/weight/left matrix/right matrix)
- tile : 在L1 (UB) 中存放的分块的
feature map/weight/left matrix/right matrix
- slice (片 = piece) : 存放在L0 (LMB/RMB) 中的对tile继续分块的
feature map/weight/left matrix/right matrix
- Instr/Cfg (config) /Ctrl : 一级模块接收的是instr, 解析后分发到二级模块的是
Cfg, 二级模块解析后分发到三级模块的是Ctrl
- FSum : full sum是Psum的反义词, 矩阵乘法在K方向上所有tile全部计算完毕的计算
结果
- 转置 : 移轴的特殊情况, 将MK $\rightarrow$ KM
- ISA : instruction set architecture指令集, 定义instr具体功能
- spec : specification (规格), 定义opentpu要支持哪些算子, 算力多少, 带宽多少
- HLD : High level description高层设计
- LLD : logic level description逻辑方案, **从需求演绎推导模块的功能划分**, 内容包括
模块的需求和功能, 在不同场景下的需求和逻辑上的具体实现, 如何根据逻辑实现推
到二级和三级模块的功能划分, 可以归一哪些模块
- CLD : circuit level description微架构电路方案, 在HLD基础上描述模块电路设计,
时序逻辑
- ViT : vision transformer : image $\rightarrow$ patch $\rightarrow$ token $\rightarrow$ attention, 把transformer
用来做图像识别
- TBD : to be determined待定
- *ceil_div* = $(x + y - 1) // y$, x/y 向上取整除法
- *GEMM* : *GE*neral *MA*trix *M*ultiply通用矩阵乘法